

Predicción de la Estabilidad Térmica de Proteínas usando Machine Learning

Informe Técnico

Presentado por:

Maria Alejandra Lizarazo P.

Ingeniería Química

Universidad de los Andes

Fecha: Mayo 2025



Abstract

This technical report presents the development of a machine learning-based tool to predict the thermal stability of proteins, measured as melting temperature (T_m), using only their primary amino acid sequence. Thermal stability is a key parameter in biotechnology, pharmaceuticals, and process engineering, yet conventional methods for determining T_m are time-consuming, expensive, and require specialized equipment.

To address these limitations, the proposed solution leverages protein embeddings generated by pretrained language models such as ESM-2, which capture structural and functional patterns directly from sequence data. Various prediction models were implemented and evaluated — including Random Forest, Bayesian Ridge, KNN, SVR, and deep learning architectures like Multilayer Perceptron (MLP) and Long Short-Term Memory (LSTM) — using curated experimental datasets such as ProthermDB and Meltome Atlas.

The LSTM model, trained with ESM-2 embeddings, achieved the best performance ($R^2 = 0.74$), showing high accuracy and generalizability. It was selected for deployment in a user-friendly web interface that allows non-technical users to input protein sequences and receive automated T_m predictions.

This work contributes to closing the gap between biological data availability and its practical use, enabling the integration of AI-powered tools in real-world applications such as protein design, enzyme engineering, and pharmaceutical research. Future work will focus on expanding the dataset, improving interpretability, and scaling the deployment architecture.

1. Resumen Ejecutivo

Este informe presenta el desarrollo de una herramienta computacional basada en aprendizaje automático para predecir la estabilidad térmica de proteínas, medida como la temperatura de fusión (T_m), a partir de su secuencia primaria de aminoácidos. La estabilidad térmica es un parámetro fundamental en biotecnología, farmacología e ingeniería de procesos, ya que determina la viabilidad funcional de una proteína en distintas condiciones operativas [14]. Tradicionalmente, el cálculo de T_m se ha realizado mediante técnicas experimentales que requieren equipamiento especializado, insumos costosos y largos tiempos de análisis.

Ante este panorama, se propone una solución computacional que utiliza representaciones numéricas avanzadas —embeddings proteicos— generadas por modelos de lenguaje como ESM-2, los cuales han sido entrenados sobre millones de secuencias proteicas. A lo largo del proyecto, se implementaron y evaluaron múltiples modelos de predicción, incluyendo algoritmos tradicionales (Random Forest, Bayesian Ridge, KNN, SVR) y redes neuronales profundas (MLP y LSTM), utilizando bases de datos experimentales como ProthermDB y Meltome Atlas (ver descripción estructurada de ambas en el Apéndice B).

Los resultados muestran que el modelo LSTM entrenado con embeddings de ESM-2 alcanzó una precisión destacable ($R^2 = 0.74$), superando a otras arquitecturas en precisión. Este modelo fue seleccionado como base para la construcción de una interfaz web, que permite a cualquier usuario ingresar una secuencia de aminoácidos y obtener una predicción inmediata de T_m , sin necesidad de conocimientos técnicos.

El sistema desarrollado contribuye a cerrar la brecha entre la disponibilidad de datos biológicos y su aprovechamiento efectivo, promoviendo la adopción de técnicas de inteligencia artificial en entornos reales. Asimismo, representa un avance significativo hacia la automatización del diseño y análisis de proteínas, con aplicaciones potenciales en el desarrollo de enzimas industriales, productos farmacéuticos y soluciones bioingenieriles. Finalmente, se plantea una hoja de ruta para futuras iteraciones que incluya mejoras en interpretabilidad, expansión de la base de datos, y despliegue en entornos escalables.

Contents

1 Resumen Ejecutivo	2
2 Introducción	4
2.1 Objetivo General	5
2.2 Objetivos Específicos	5
3 Conceptos Clave	6
3.1 Temperatura de Fusión (T_m)	6
3.2 Estabilidad Térmica de Proteínas	6
3.3 Embeddings Proteicos	6
3.4 Modelos de Lenguaje ESM-2 y ProtTrans	7
3.5 Modelos de Aprendizaje Automático	7
3.6 Interfaz Web para Inferencia	7
3.7 Validación Cruzada y Métricas de Evaluación	7
4 Primera Iteración: Desarrollo Inicial con ProthermDB	8
4.1 Objetivo y Alcance	8
4.2 Modelos y Metodología	9
4.3 Resultados	9
4.4 Discusión	9
5 Segunda Iteración: Modelado con una Base de Datos Más Robusta	10
5.1 Objetivo y Alcance	10
5.2 Modelos y Metodología	10
5.3 Resultados	11
5.4 Discusión	11
6 Tercera Iteración: Modelo Final con Toda la Base de Meltome Atlas	12
6.1 Objetivo y Alcance	12

6.2 Modelos y Metodología	12
6.3 Resultados	13
6.4 Distribución del error y residuales (LSTM)	14
6.5 Distribución del error y residuales (MLP)	15
6.6 Discusión	16
7 Implementación de la Interfaz Web para Inferencia	18
7.1 Objetivo y Alcance	18
7.2 Flujo Funcional de Inferencia	18
7.3 Arquitectura Técnica de Despliegue	20
7.4 Resultados y Ventajas	21
7.5 Decisiones Finales y Preparación para Entorno Productivo	21
8 Conclusiones Generales y Próximos Pasos	22
8.1 Discusión General	22
8.2 Conclusiones y Proyecciones	22

2. Introducción

La estabilidad térmica de las proteínas es un parámetro fundamental para numerosas aplicaciones en biotecnología, farmacología e ingeniería de procesos. Conocer la temperatura a la cual una proteína pierde su estructura nativa —conocida como temperatura de fusión o T_m — permite optimizar condiciones experimentales, diseñar proteínas resistentes y reducir riesgos asociados a la pérdida de funcionalidad en entornos industriales exigentes [2, 3, 14].

La capacidad de predecir T_m con precisión tiene implicaciones prácticas en diversos sectores. En la industria farmacéutica, permite identificar proteínas candidatas más estables para su formulación y transporte. En biotecnología industrial, facilita el diseño de enzimas que mantengan su actividad catalítica en ambientes de alta temperatura. Además, en bioingeniería y biología sintética, posibilita la modificación racional de proteínas para mejorar su rendimiento en condiciones específicas sin necesidad de realizar múltiples ensayos experimentales.

Tradicionalmente, la determinación de T_m se ha realizado mediante técnicas experimentales costosas y lentas, que requieren equipamiento especializado y materiales difíciles de obtener a gran escala. En este contexto, las predicciones computacionales se presentan como una alternativa eficiente, rápida y escalable para estimar la estabilidad térmica de proteínas directamente a partir de su secuencia de aminoácidos [15].

Este trabajo se enmarca dentro de un panorama más amplio en el que la biología computacional enfrenta un desfase entre la cantidad de datos generados y el conocimiento útil que puede derivarse de ellos, lo que ha sido descrito como una “brecha de conocimiento” en la bioinformática moderna [7]. Para cerrar esta brecha, es crucial desarrollar herramientas automatizadas, accesibles y con potencial de impacto práctico. Además, la adopción efectiva de tecnologías computacionales en entornos reales depende no solo de su precisión técnica,

sino también de su accesibilidad para usuarios no expertos, quienes enfrentan barreras técnicas que limitan su implementación [9].

Este estudio presenta el desarrollo de una solución basada en Machine Learning para predecir la temperatura de fusión de proteínas utilizando únicamente su secuencia primaria. Para ello, se emplearon embeddings proteicos generados por modelos de lenguaje preentrenados en grandes bases de datos biológicas, los cuales permiten capturar patrones evolutivos y estructurales relevantes sin necesidad de alineamientos múltiples o estructuras tridimensionales.

Además del desarrollo y validación de múltiples modelos de predicción, este trabajo incorpora una interfaz web sencilla e intuitiva que permite a cualquier usuario —incluso sin conocimientos técnicos— ingresar una secuencia de aminoácidos y obtener una predicción automática de T_m . Esta herramienta, pensada para el uso de investigadores y profesionales en la industria, busca reducir las barreras de acceso al uso de modelos avanzados de aprendizaje automático, promoviendo su adopción práctica. El diseño considera principios de alfabetización computacional y entendimiento funcional por parte de usuarios con formación diversa, elemento clave para lograr adopción efectiva en contextos interdisciplinarios [8].

A lo largo del documento, se describe el proceso completo de desarrollo: desde la recolección y limpieza de datos hasta el entrenamiento de modelos y evaluación comparativa de distintos enfoques. Se presentan los resultados obtenidos, se discuten sus implicaciones y se propone una hoja de ruta para futuras mejoras, tanto en la precisión del modelo como en su usabilidad.

Cabe aclarar que este trabajo se centra exclusivamente en proteínas tipo *wild-type*, es decir, aquellas sin mutaciones artificiales o naturales reportadas en su secuencia. Esta decisión se tomó para asegurar consistencia estructural y evitar sesgos derivados de variantes muy similares en la base de datos. Sin embargo, algunos estudios han demostrado que modelos basados en secuencias *wild-type* pueden ser parcialmente útiles como base para estimar el efecto de mutaciones puntuales sobre la estabilidad térmica, siempre y cuando estas no alteren drásticamente la estructura terciaria [10, 11]. No obstante, se requiere precaución al extrapolar fuera del dominio entrenado.

2.1 Objetivo General

Desarrollar un modelo de predicción de la estabilidad térmica de proteínas, medido como la temperatura de fusión (T_m), utilizando únicamente su secuencia de aminoácidos, a través de técnicas de aprendizaje automático basadas en embeddings generados por modelos de lenguaje entrenados en bases de datos biológicas, y presentar una interfaz web funcional que permita la consulta de predicciones de manera intuitiva.

2.2 Objetivos Específicos

- Desarrollar un proceso de adquisición, limpieza y procesamiento de datos utilizados en el entrenamiento del modelo, asegurando la correcta extracción de información desde bases como ProthermDB y Meltome Atlas.

- Evaluar la viabilidad de utilizar embeddings proteicos generados por modelos preentrenados (ESM-2 y ProtTrans) para representar secuencias de aminoácidos sin necesidad de estructuras tridimensionales [21].
- Entrenar y comparar múltiples modelos de aprendizaje automático, incluyendo redes neuronales profundas como la red neuronal multicapa (Multilayer Perceptron, MLP) y la red neuronal de memoria a largo plazo (Long Short-Term Memory, LSTM), así como modelos tradicionales como el bosque aleatorio (Random Forest), utilizando datos experimentales curados provenientes de distintas bases, incluyendo ProthermDB y datos complementarios.
- Validar la precisión del modelo final mediante métricas estándar (MAE, MSE, R^2), y discutir sus implicaciones en aplicaciones reales en biotecnología, ingeniería de proteínas y diseño experimental.
- Diseñar una arquitectura de interfaz web que permita a usuarios sin conocimientos técnicos ingresar una secuencia de aminoácidos y obtener la predicción de T_m de forma automática.
- Identificar y proponer posibles líneas de mejora del modelo, incluyendo aspectos como interpretabilidad, escalabilidad, incorporación de nuevas propiedades biofísicas y estrategias para el despliegue web sostenible, con el fin de guiar futuras iteraciones y facilitar su adopción en contextos de investigación e industria.

3. Conceptos Clave

3.1 Temperatura de Fusión (T_m)

La temperatura de fusión (T_m) de una proteína corresponde a la temperatura en la cual el 50% de las moléculas proteicas en una muestra pierden su conformación nativa debido a la desnaturalización térmica. Este valor se considera un indicador clave de la estabilidad térmica de la proteína, ya que refleja el punto de equilibrio entre las formas nativa y desnaturalizada. Su medición es fundamental en contextos industriales y farmacéuticos, donde se requiere asegurar la funcionalidad de las proteínas bajo condiciones térmicas variables.

3.2 Estabilidad Térmica de Proteínas

La estabilidad térmica de una proteína se refiere a su capacidad para mantener su estructura tridimensional nativa y, por ende, su funcionalidad biológica, cuando es expuesta a incrementos de temperatura. Una mayor estabilidad térmica indica una mayor resistencia al desdoblamiento (*unfolding*) térmico, lo cual es esencial en aplicaciones donde las proteínas deben operar en condiciones exigentes, como procesos industriales, ambientes extremos o formulaciones farmacéuticas.

3.3 Embeddings Proteicos

Son representaciones numéricas de secuencias de aminoácidos generadas por modelos de lenguaje. Permiten capturar propiedades estructurales y funcionales sin necesidad de estructuras tridimensionales o alineamientos.

3.4 Modelos de Lenguaje ESM-2 y ProtTrans

ESM-2 y ProtTrans son modelos de lenguaje preentrenados utilizados para generar embeddings proteicos a partir de millones de secuencias, cuya descripción detallada se encuentra en el Apéndice A.

3.5 Modelos de Aprendizaje Automático

A lo largo del proyecto se exploraron diferentes algoritmos dentro del paradigma de **aprendizaje supervisado**. En este enfoque, el modelo aprende a mapear una entrada (secuencia de aminoácidos) con una salida conocida (temperatura de fusión T_m), con el objetivo de generalizar a nuevas muestras no vistas.

A continuación, se describen los principales modelos utilizados:

- **Red Neuronal Multicapa (Multilayer Perceptron, MLP):** Modelo compuesto por varias capas densamente conectadas. Aprende relaciones no lineales entre variables y es común en tareas de regresión como la predicción de propiedades biofísicas.
- **Red Neuronal de Memoria a Largo Plazo (Long Short-Term Memory, LSTM):** Arquitectura recurrente especializada en secuencias. Captura dependencias entre elementos consecutivos, útil cuando el orden de los aminoácidos es relevante para la predicción.
- **Bosque Aleatorio (Random Forest):** Conjunto de árboles de decisión que trabajan en paralelo. Cada árbol genera una predicción, y el modelo promedia los resultados. Es robusto ante ruido y útil como línea base.

Además, para mejorar el rendimiento de los modelos neuronales, se aplicaron técnicas de regularización como:

- **Redes Neuronales Densas (Fully Connected Networks):** Arquitecturas donde cada neurona está conectada con todas las de la siguiente capa. Base estructural de modelos como MLP.
- **Técnica de Dropout:** Método que desactiva aleatoriamente un porcentaje de neuronas durante el entrenamiento. Previene el sobreajuste y mejora la generalización del modelo [16].

3.6 Interfaz Web para Inferencia

Es una aplicación accesible vía navegador que permite a los usuarios ingresar una secuencia de aminoácidos y obtener automáticamente una predicción de T_m . Su propósito es democratizar el uso del modelo sin necesidad de conocimientos técnicos o instalación local.

3.7 Validación Cruzada y Métricas de Evaluación

La validación cruzada es una técnica que divide los datos en múltiples subconjuntos para evaluar la generalización del modelo. Las métricas comunes incluyen:

- **Error Absoluto Medio (MAE):** Calcula la media de los errores absolutos entre las predicciones y los valores reales. Es intuitivo y robusto ante valores atípicos.
- **Error Cuadrático Medio (MSE):** Penaliza fuertemente los errores grandes al elevarlos al cuadrado. Es útil cuando se desea minimizar desviaciones severas.
- **Raíz del Error Cuadrático Medio (RMSE):** Es la raíz cuadrada del MSE y está en las mismas unidades que la variable objetivo (T_m), facilitando su interpretación.
- **Coefficiente de Determinación (R^2):** Mide qué proporción de la variabilidad de los datos es explicada por el modelo. Valores cercanos a 1 indican un buen ajuste, mientras que valores negativos indican que el modelo es peor que simplemente predecir el promedio.
- **Coefficiente de Correlación de Pearson (PCC):** Mide la fuerza y dirección de la relación lineal entre los valores predichos y los valores reales. Su valor varía entre -1 y 1 : valores cercanos a 1 indican una fuerte correlación positiva, valores cercanos a -1 una fuerte correlación negativa, y valores cercanos a 0 indican ausencia de relación lineal. A diferencia del R^2 , el PCC no depende del ajuste de una recta, sino únicamente de la consistencia en la tendencia entre las dos variables.

Iteraciones del Desarrollo del Modelo

El proceso de desarrollo de esta solución se estructuró en tres iteraciones consecutivas, cada una enfocada en superar limitaciones identificadas en la fase anterior y mejorar la precisión y escalabilidad del modelo. Estas iteraciones incluyeron la exploración de distintas bases de datos experimentales, la comparación de múltiples arquitecturas de aprendizaje automático y la evaluación sistemática de su desempeño. A continuación, se presenta una descripción detallada de cada iteración, incluyendo los objetivos, metodologías, resultados obtenidos y las decisiones estratégicas que guiaron la evolución del proyecto.

4. Primera Iteración: Desarrollo Inicial con ProthermDB

4.1 Objetivo y Alcance

La primera iteración consistió en desarrollar un flujo de trabajo completo para predecir la temperatura de fusión (T_m) de proteínas utilizando como fuente de datos la base ProthermDB [17]. Esta base contiene datos experimentales curados sobre estabilidad de proteínas y fue seleccionada por ser una de las referencias más utilizadas en estudios similares. Se utilizó el conjunto completo de registros disponibles (aproximadamente 11,000 entradas) y se aplicó un proceso de limpieza para eliminar entradas con valores faltantes o inconsistentes.

4.2 Modelos y Metodología

Las secuencias fueron transformadas en embeddings utilizando dos modelos preentrenados ampliamente aceptados:

- **ESM-2 (Evolutionary Scale Modeling 2):** Modelo basado en arquitectura Transformer, entrenado sobre grandes corpus de datos proteicos.
- **ProtTrans:** Conjunto de modelos que incluye BERT y T5, diseñados específicamente para tareas bioinformáticas.

Se entrenó una red neuronal densa sencilla con activaciones ReLU y función de pérdida MSE. Los datos fueron divididos en 80% entrenamiento y 20% validación. Las métricas evaluadas incluyeron MAE, RMSE y R^2 .

4.3 Resultados

Modelo	MAE	MSE	RMSE	R^2
ESM-2	0.6610	0.7346	0.8571	0.3033
ProtTrans	0.7720	0.9218	0.9601	-0.0004

Table 1: Desempeño comparativo de modelos en la primera iteración

4.4 Discusión

Los resultados muestran que el modelo basado en embeddings de ESM-2 supera de forma consistente al modelo basado en ProtTrans, tanto en precisión como en capacidad de generalización. Aunque ambos lograron aprender patrones relevantes, el desempeño de ProtTrans fue menor, con un R^2 cercano a cero.

Este análisis reveló que, si bien ProthermDB es útil como punto de partida, presenta limitaciones: tamaño moderado, cobertura parcial de secuencias y potencial redundancia entre entradas. Esto motivó la búsqueda de una base de datos más amplia y representativa, capaz de mejorar la robustez del modelo.

Asimismo, se identificó la necesidad de probar arquitecturas más complejas (como MLP y LSTM), así como modelos de referencia tradicionales (Random Forest), para evaluar su potencial comparativo. Estas decisiones fundamentaron la segunda iteración del proyecto, centrada en la ampliación y diversificación del conjunto de datos y el diseño de modelos más sofisticados.

Decisiones Tomadas y Motivación para la Siguiente Iteración

- Se decidió mantener el uso de embeddings generados por el modelo ESM-2, debido a su mejor desempeño frente a ProtTrans en todos los indicadores evaluados.

- Se identificó un posible factor de sobreajuste relacionado con la composición de la base de datos ProthermDB. Dado que esta base incluye múltiples mutaciones de una misma proteína como entradas independientes, el modelo podía entrenarse repetidamente sobre variantes casi idénticas (por ejemplo, AAA, AAB, AAC), lo que favorecía la memorización de patrones locales. Esto perjudicaba la capacidad de generalización del modelo frente a proteínas distintas (como BBA o BBC), reduciendo su aplicabilidad práctica.
- Por esta razón, se propuso explorar un conjunto de datos más grande y diversificado, con mejor control sobre la redundancia entre secuencias. Particularmente, se consideró separar explícitamente proteínas tipo *wild-type* de aquellas mutadas, o emplear estrategias de agrupamiento previo para evitar fugas de información entre entrenamiento y validación.
- Se planteó también la evaluación de arquitecturas más complejas, como redes neuronales multicapa y modelos secuenciales tipo LSTM, junto con modelos tradicionales como Random Forest, para establecer líneas base más robustas.
- Finalmente, se propuso iniciar el diseño de una interfaz web que permitiera realizar inferencia sobre nuevas secuencias de manera accesible, sin necesidad de conocimientos técnicos o configuración local.

Esta iteración sirvió como base para estructurar y refinar la estrategia general de modelado, validando el potencial del enfoque y estableciendo una línea base comparativa para las siguientes fases del proyecto.

5. Segunda Iteración: Modelado con una Base de Datos Más Robusta

5.1 Objetivo y Alcance

La segunda iteración se centró en superar las limitaciones identificadas en la fase anterior mediante el uso de una base de datos más extensa y curada: Meltome Atlas [18]. Esta base ofrece información sobre la temperatura de fusión de proteínas tipo *wild-type* en condiciones experimentales controladas, eliminando la redundancia presente en ProthermDB derivada de mutaciones múltiples sobre la misma proteína. En total, se dispuso de aproximadamente 25 000 secuencias con datos de estabilidad térmica, lo que representa una mejora significativa en diversidad y volumen.

5.2 Modelos y Metodología

Se conservaron los embeddings generados con el modelo ESM-2, dada su efectividad comprobada en la primera iteración. Estos embeddings, de tamaño 1280 por secuencia, fueron utilizados como entrada para entrenar varios modelos de regresión, incluyendo algoritmos tradicionales y redes neuronales.

Inicialmente, se exploró el uso de **Random Forest**, debido a su capacidad para manejar relaciones no lineales, su robustez ante ruido y su buena interpretación como línea base. Sin embargo, una limitación importante fue la

escalabilidad: al no estar optimizado para uso con GPU, el entrenamiento completo con la base Meltome se tornó inviable en términos de tiempo y recursos computacionales [23–25]. Como resultado, se trabajó con una muestra reducida de 2335 secuencias representativas para esta fase exploratoria.

Se comparó el desempeño de Random Forest con otros modelos tradicionales como SVR, KNN, Bayesian Ridge y una red neuronal multicapa sencilla (MLPRegressor).

5.3 Resultados

Modelo	MAE	RMSE	R^2	PCC
Random Forest	6.1208	8.5679	0.8082	0.8992
Bayesian Ridge	6.5397	8.9346	0.7914	0.8908
KNN	6.1149	8.9968	0.7885	0.8936
SVR	6.9572	9.8451	0.7468	0.8689
MLPRegressor	7.1596	9.7690	0.7507	0.8716

Table 2: Comparación de modelos con muestra reducida de Meltome Atlas

5.4 Discusión

Los resultados muestran que el modelo Random Forest tuvo el mejor desempeño entre los métodos evaluados, tanto en términos de error absoluto medio como de capacidad explicativa. Su habilidad para capturar relaciones no lineales sin requerir una arquitectura compleja lo convierte en una excelente línea base.

No obstante, su imposibilidad de utilizar GPU representó una barrera significativa: el entrenamiento sobre la totalidad de Meltome Atlas requería tiempos de cómputo poco prácticos. Esto limitó el uso de esta estrategia a subconjuntos representativos de los datos, lo cual impidió aprovechar el potencial completo de la base.

Dado que los modelos neuronales como MLP y LSTM sí pueden entrenarse en GPU y escalar a decenas de miles de muestras, se decidió abandonar Random Forest en favor de estos enfoques más adaptables para la tercera iteración.

Decisiones Tomadas y Motivación para la Siguiente Iteración

- Se reafirmó el uso de embeddings generados con ESM-2, al demostrar consistencia y buena capacidad representacional incluso con nuevos datos.
- Se identificó a Random Forest como un modelo robusto en pequeñas muestras, pero inadecuado para la escala total de datos disponibles debido a su limitación de entrenamiento en CPU.
- Se decidió entrenar redes neuronales profundas como MLP (Multilayer Perceptron) y LSTM (Long Short-Term Memory), aprovechando el soporte de entrenamiento en GPU para trabajar con la totalidad del corpus.

- Se mantuvo la idea de construir una interfaz para inferencia web, y se comenzó a estructurar el almacenamiento y preprocesamiento de embeddings con vistas a una futura integración.

6. Tercera Iteración: Modelo Final con Toda la Base de Meltome Atlas

6.1 Objetivo y Alcance

La tercera iteración tuvo como objetivo entrenar un modelo robusto de predicción de temperatura de fusión (T_m) utilizando el conjunto completo de datos *wild-type* del proyecto Meltome Atlas. A diferencia de la segunda iteración, que se limitó a un subconjunto de datos debido a restricciones de memoria y CPU al usar Random Forest, en esta etapa se aprovechó el uso de arquitecturas compatibles con entrenamiento en GPU (como MLP y LSTM), lo que permitió escalar el proceso a más de 20,000 muestras.

6.2 Modelos y Metodología

El proceso completo incluyó:

- **Preprocesamiento:** Las secuencias aminoacídicas fueron obtenidas utilizando la API de UniProt (ver Apéndice C), a partir de los identificadores `UniProt_ID` contenidos en la tabla `cross-species.csv` la cual se obtuvo de la base de datos Meltome Atlas. Esta tabla actúa como metadatos y contiene la correspondencia entre proteínas, organismos y sus valores de temperatura de fusión (T_m). Para garantizar la calidad del conjunto de datos, se implementó un proceso de limpieza que incluyó: eliminación de entradas con valores nulos en T_m , exclusión de secuencias repetidas, y filtrado de proteínas incompletas o mal formateadas. Adicionalmente, se descartaron registros con caracteres inválidos en la secuencia (por ejemplo, secuencias con 'X' o símbolos no estándar).
- **Embeddings:** Se utilizaron los embeddings generados por el modelo `ESM-2 facebook/esm2_t33_650M_UR50D` de HuggingFace. Cada secuencia se transformó en un vector de 1280 dimensiones y se almacenó en un archivo HDF5.
- **Modelos evaluados:**
 - **MLP (Multilayer Perceptron):** Arquitectura densa con múltiples capas ocultas, adecuada para relaciones no secuenciales en los datos.
 - **LSTM (Long Short-Term Memory):** Red neuronal recurrente especializada en secuencias, ideal para capturar la dependencia entre posiciones en la secuencia de aminoácidos.

Los modelos fueron entrenados usando `PyTorch`, dividiendo los datos en 80% entrenamiento y 20% validación. Se utilizaron las métricas MAE, MSE, RMSE y R^2 para la evaluación.

La Figura 1 presenta el flujo completo de procesamiento y entrenamiento del modelo, desde la integración de datos de Meltome Atlas hasta la generación de embeddings con ESM-2 y el entrenamiento de modelos como MLP y LSTM.




Figure 1: Flujo completo de procesamiento y entrenamiento del modelo final, desde la base de datos Meltome Atlas hasta la generación de embeddings y entrenamiento con modelos LSTM y MLP.

6.3 Resultados

La Tabla 3 presenta una comparación de las métricas de desempeño entre los modelos MLP y LSTM al ser entrenados con la totalidad de los datos del Meltome Atlas. Se observa que el modelo LSTM presenta un error medio absoluto (MAE) ligeramente menor, así como un mejor coeficiente de determinación ($R^2 = 0.74$) frente al MLP ($R^2 = 0.72$).

Modelo	MAE	MSE	RMSE	R^2
MLP	4.74	38.06	6.16	0.72
LSTM	4.54	34.57	5.88	0.74

Table 3: Comparación de métricas para MLP y LSTM usando todos los datos de Meltome Atlas

Para profundizar en la evaluación de errores, las Figuras 2, 3 y 4 muestran, respectivamente, la distribución del error, la relación entre valores predichos y reales, y los residuos del modelo LSTM. De forma análoga, las Figuras 5, 6 y 7 presentan los mismos análisis para el modelo MLP.

6.4 Distribución del error y residuales (LSTM)




Figure 2: Distribución de errores absolutos para el modelo LSTM. Se observa una concentración alrededor de 0–5 °C, con algunos valores extremos.




Figure 3: Comparación entre temperaturas predichas y reales para el modelo LSTM. La mayoría de los puntos se agrupan cerca de la diagonal.




Figure 4: Distribución de residuos del modelo LSTM. Se observa heterocedasticidad con mayor dispersión en los extremos del rango de temperatura.

6.5 Distribución del error y residuales (MLP)




Figure 5: Distribución de errores absolutos para el modelo MLP. Los errores tienden a concentrarse en valores entre 0–6 °C.




Figure 6: Comparación entre temperaturas predichas y reales para el modelo MLP. La dispersión es ligeramente mayor en los valores extremos.




Figure 7: Distribución de residuos del modelo MLP. También presenta cierta heterocedasticidad, con tendencia a subestimar en temperaturas altas.

6.6 Discusión

Ambos modelos lograron un rendimiento sólido, con coeficientes de determinación (R^2) superiores al 0.70. El modelo basado en LSTM obtuvo una ligera ventaja en las métricas MAE y RMSE, lo que sugiere una capacidad

ligeramente mejor de generalización. Sin embargo, un análisis más detallado de los gráficos de error y residuales revela comportamientos diferenciales relevantes entre ambos modelos.

Gráficas de Residuales:

- Para el modelo **MLP**, la gráfica de residuales muestra un patrón de dispersión creciente a medida que aumentan los valores predichos, lo que indica heteroscedasticidad, lo que significa que la variabilidad del error no es constante a lo largo de los valores predichos, sino que aumenta o disminuye dependiendo del valor de entrada. En particular, los residuales tienden a aumentar en magnitud en los valores altos de T_m , lo que sugiere que el modelo subestima sistemáticamente las temperaturas elevadas. Además, se observa un agrupamiento denso de puntos alrededor de predicciones cercanas a 50°C, lo que refleja que el modelo ha aprendido adecuadamente la tendencia central de los datos, pero tiene dificultades para capturar las colas de la distribución. Esta tendencia sugiere un sesgo en los extremos y posible necesidad de regularización adicional o transformación no lineal de las entradas.
- En el caso del **LSTM**, aunque los residuales presentan una distribución más simétrica, se detecta una “banding” o agrupación horizontal en valores altos predichos, lo que sugiere saturación de salida o *vanishing gradients*. Es decir, el modelo tiende a comprimir las predicciones en el rango alto (por ejemplo, muchas predicciones se agrupan en torno a 85°C), limitando su capacidad de capturar variabilidad en la cola superior. Esto podría ser consecuencia de una mala configuración de la función de activación en la capa de salida o de un escalamiento inadecuado de las variables objetivo durante el entrenamiento.

Predicciones vs. Valores Reales:

- En el **MLP**, las predicciones muestran una alineación casi lineal con los valores reales en el rango medio. Sin embargo, a medida que los valores reales aumentan, las predicciones tienden a quedarse cortas, evidenciando un subajuste en los extremos superiores. Esto es consistente con el patrón observado en los residuales.
- Para el **LSTM**, el gráfico de predicciones vs. reales exhibe una fuerte compresión en los valores altos, generando una meseta alrededor de los 85°C. Esta falta de sensibilidad a variaciones altas sugiere un sesgo estructural del modelo, posiblemente relacionado con la arquitectura, el número de épocas de entrenamiento o la normalización de las salidas.

Distribución de Errores:

- El histograma de errores del **MLP** presenta una forma aproximadamente normal centrada en cero, pero con una ligera cola hacia la izquierda, lo que sugiere algunas subestimaciones esporádicas significativas.
- En contraste, el modelo **LSTM** muestra una distribución más simétrica y también centrada en cero, lo que indica que, en promedio, no está sesgado. Sin embargo, como se mencionó antes, este comportamiento

no se traduce en predicciones igualmente distribuidas, ya que el sesgo se presenta en los extremos de la variable objetivo, no en el error promedio.

Consideraciones Finales:

Ambos modelos tienen puntos fuertes: el **MLP** maneja bien los valores centrales y muestra menor saturación en la salida, mientras que el **LSTM** presenta una distribución de errores más consistente. Sin embargo, ambos exhiben dificultades para modelar correctamente los extremos del rango de T_m .

Para mejorar estos resultados, se recomienda:

- **MLP:** Probar arquitecturas más profundas, incluir capas de regularización como *dropout*, o ajustar la función de pérdida (por ejemplo, *Huber loss*) para reducir el impacto de valores extremos.
- **LSTM:** Revisar la función de activación de la salida (considerar reemplazar *tanh/sigmoid* por *ReLU* o lineal), y rescalar la variable objetivo para facilitar el aprendizaje en valores altos.
- **Ambos modelos:** Aplicar técnicas de ingeniería de características, como la introducción de interacciones o transformaciones polinómicas, y considerar el uso de métodos como regresión por cuantiles o ensambles para capturar mejor la incertidumbre.

Decisiones Tomadas y Selección del Modelo Final

- Se seleccionó el modelo **LSTM** como el mejor candidato para ser desplegado en la interfaz web, debido a su mejor rendimiento general.
- El MLP, aunque competitivo, es ligeramente menos eficiente que LSTM.
- Se decidió conservar ambos modelos para análisis futuros, pero únicamente el LSTM será empaquetado para uso por parte de usuarios no técnicos en la plataforma web de predicción.

7. Implementación de la Interfaz Web para Inferencia

7.1 Objetivo y Alcance

El objetivo de esta iteración fue diseñar y desplegar una interfaz accesible que permitiera realizar inferencias con el modelo entrenado sin requerir conocimientos técnicos o instalaciones locales. Esta herramienta web permite a cualquier usuario ingresar una secuencia aminoacídica y obtener una predicción instantánea de su temperatura de fusión (T_m) directamente desde el navegador.

7.2 Flujo Funcional de Inferencia

La arquitectura funcional del sistema incluye los siguientes componentes principales:

- **Frontend:** Una página web desarrollada en HTML y JavaScript que permite el ingreso de secuencias individuales o por lote (archivos CSV o Excel).
- **Backend en Flask:** Se encarga de recibir las secuencias, generar los embeddings y ejecutar el modelo entrenado para retornar la predicción.
- **Modelo de Inferencia:** Compuesto por el modelo ESM-2 de HuggingFace para generación de embeddings y un modelo LSTM entrenado para predecir la temperatura de fusión.

El flujo completo de inferencia y respuesta se resume en la Figura 8. Este describe la interacción del usuario con la interfaz, el procesamiento interno y la entrega del resultado.




Figure 8: Diagrama general del flujo de inferencia para predicción de estabilidad térmica. La flecha de retorno indica la entrega del resultado a la interfaz web.

Pasos del flujo:

1. El usuario ingresa una secuencia aminoacídica en la interfaz web.
2. El backend genera el embedding utilizando el modelo preentrenado `facebook/esm2_t33_650M_UR50D`.
3. El embedding es procesado por el modelo LSTM entrenado.

4. Se devuelve al usuario la predicción de temperatura de fusión (T_m) estimada, ya sea en pantalla o como archivo descargable.




Figure 9: Vista de la interfaz web desarrollada para predicción de temperatura de fusión a partir de una secuencia de aminoácidos.

7.3 Arquitectura Técnica de Despliegue

La solución fue desplegada en una máquina virtual de la Universidad de los Andes con las siguientes características:

- **Sistema Operativo:** Ubuntu Server 22.04 LTS
- **Dirección IP:** [redacted]
- **Recursos:** 4 núcleos de CPU, 16 GB de RAM, 100 GB de almacenamiento
- **GPU:** 2 unidades NVIDIA A40-16C con 16 GB de memoria cada una

La Figura 10 muestra el esquema completo de despliegue técnico:




Figure 10: Arquitectura de despliegue técnico en máquina virtual con Docker y GPU habilitada para el modelo de inferencia.

7.4 Resultados y Ventajas

La interfaz web desplegada permite acceso inmediato a la inferencia sin requerir configuración local por parte del usuario final. Entre sus ventajas:

- Democratiza el acceso a modelos complejos de Machine Learning.
- Permite predicciones tanto individuales como por lote.
- Escalable a ambientes industriales o de investigación.

7.5 Decisiones Finales y Preparación para Entorno Productivo

Esta versión final opera con estabilidad en GPU, expone una API funcional para predicción, y puede integrarse con herramientas de monitoreo, autenticación o plataformas en la nube como Render o Railway. Esto permite un despliegue productivo realista en contextos farmacéuticos, académicos o de investigación.

8. Conclusiones Generales y Próximos Pasos

8.1 Discusión General

Este trabajo presentó el desarrollo progresivo de una solución basada en aprendizaje automático para predecir la estabilidad térmica de proteínas, expresada como la temperatura de fusión (T_m), a partir de su secuencia aminoacídica. A lo largo de cuatro iteraciones consecutivas, se consolidó un flujo robusto de recolección de datos, transformación mediante embeddings proteicos, entrenamiento de modelos, y despliegue funcional en una interfaz web accesible.

En la primera fase, el uso de ProthermDB permitió validar el pipeline inicial, identificar fortalezas del modelo ESM-2 y reconocer problemas como la redundancia de mutaciones. Posteriormente, la incorporación de Meltome Atlas en la segunda iteración elevó la diversidad y calidad de los datos. Aunque Random Forest ofreció un rendimiento competitivo, su falta de compatibilidad con GPU restringió su aplicabilidad a grandes volúmenes.

La tercera iteración consolidó el uso de modelos neuronales como MLP y LSTM entrenados sobre más de 20,000 secuencias. El LSTM mostró un desempeño levemente superior ($MAE = 4.54$, $R^2 = 0.74$), acompañado de menor complejidad computacional, haciéndolo idóneo para despliegue. Finalmente, se construyó una interfaz web funcional en la cuarta iteración, con soporte para procesamiento e inferencia automática, marcando la transición del proyecto hacia una herramienta práctica.

8.2 Conclusiones y Proyecciones

- El uso de embeddings generados por modelos de lenguaje como ESM-2 demostró ser efectivo para representar propiedades biofísicas complejas de las proteínas sin necesidad de alineamientos o estructuras 3D.
- La combinación de una base de datos extensa (Meltome Atlas) con modelos escalables (MLP y LSTM) permitió entrenar predictores de temperatura de fusión con precisión aceptable, con un R^2 superior a 0.70, lo cual es destacable para datos biológicos.
- El modelo LSTM fue seleccionado como la solución final debido a su equilibrio entre rendimiento, velocidad de inferencia y facilidad de implementación, siendo empacado exitosamente en una interfaz web interactiva.
- Se identificaron oportunidades de mejora para futuras versiones del sistema:
 - Implementar estrategias de normalización por familia proteica o tipo de organismo para reducir errores sistemáticos en los extremos de temperatura.
 - Explorar arquitecturas híbridas o enfoques de *ensemble* que combinen las fortalezas de modelos como MLP y LSTM para mejorar la precisión.
 - Evaluar estrategias de interpretación del modelo (por ejemplo, *saliency maps*) que permitan entender qué regiones de la secuencia contribuyen más a la predicción, favoreciendo su adopción en entornos

científicos.

- Preparar el entorno para despliegue en nube (por ejemplo, Render o Railway) con escalabilidad automática y soporte para múltiples usuarios concurrentes.
- Considerar una reevaluación controlada del modelo **ProtTrans**, bajo condiciones metodológicas similares a ESM-2 y usando la base Meltome, con el fin de descartar errores de implementación previos y validar su desempeño real como comparativo.
- Incluir modelos especializados en la predicción de variaciones en la estabilidad térmica causadas por mutaciones puntuales (ΔT_m). Herramientas como HoTMuSiC [15] y otros modelos de regresión y redes neuronales han demostrado ser útiles para estimar el efecto de cambios específicos en la secuencia sobre la temperatura de fusión [13]. Integrar este tipo de predicciones como módulo complementario permitiría extender el uso del sistema a escenarios donde se conocen mutaciones concretas, aportando mayor precisión y utilidad práctica.
- Analizar agrupamientos en el espacio de embeddings: se observó que algunas predicciones generadas por el modelo LSTM tienden a agruparse en ciertas regiones del espacio de salida. Esto sugiere que los embeddings generados por ESM-2 podrían estar reflejando propiedades fisicoquímicas latentes (como estructura secundaria, carga o funciones similares). Se propone realizar un análisis exploratorio del espacio de embeddings usando técnicas como t-SNE o UMAP, seguido de métodos de agrupamiento (*clustering*). Este análisis permitiría:
 - * Visualizar si existen regiones diferenciadas que correspondan a tipos específicos de proteínas.
 - * Evaluar si los errores del modelo se concentran en regiones específicas del espacio, lo que puede informar mejoras en el entrenamiento.
 - * Identificar propiedades fisicoquímicas relevantes para incorporarlas explícitamente en el modelo o como características auxiliares.

Este enfoque puede mejorar tanto la precisión como la interpretabilidad del sistema, lo cual es clave para su aplicación en contextos científicos y de ingeniería de proteínas.

En complemento a los elementos listados previamente, se propone explorar modelos híbridos tanto a nivel arquitectural como funcional. Desde una perspectiva estructural, se han reportado combinaciones de capas convolucionales (CNN) con redes recurrentes como LSTM que capturan simultáneamente patrones locales y dependencias de largo alcance en secuencias proteicas. Estas arquitecturas han demostrado ser útiles en tareas como predicción de estructuras secundarias, sitios activos o enlaces de unión, y podrían adaptarse para mejorar la predicción de T_m . También se han utilizado enfoques de atención (como mecanismos derivados de Transformers) para identificar regiones clave de la secuencia con alta relevancia para la propiedad objetivo, como lo hacen modelos como NetSurfP-2.0 [19] o ProtBert-BFD [22].

Por otra parte, existen modelos híbridos desde el punto de vista funcional, que integran la predicción de T_m absoluto con la estimación de cambios en la estabilidad térmica inducidos por mutaciones puntuales (ΔT_m).

Herramientas como PON-Tm [10] y HoTMuSiC [15] incorporan esta funcionalidad, ya sea a partir de diferencias entre embeddings o del análisis estructural. En futuras versiones del sistema propuesto, podría integrarse un módulo que reciba tanto la secuencia original como la mutada, y prediga el efecto diferencial sobre T_m , permitiendo su aplicación a tareas de diseño racional, escaneo de variantes y optimización evolutiva. Esto convertiría la herramienta no solo en un predictor directo, sino también en un asistente de ingeniería de proteínas, cubriendo un espectro funcional más amplio dentro del desarrollo bioinformático.

En resumen, aunque este trabajo se enfoca en un modelo ligero y funcional que opera únicamente sobre secuencias *wild-type*, se reconocen diversas estrategias que podrían enriquecer su capacidad predictiva en el futuro. Estas alternativas deben evaluarse cuidadosamente para asegurar que el equilibrio entre precisión, interpretabilidad y accesibilidad se mantenga como eje central del desarrollo.

Esta solución sienta las bases para aplicaciones prácticas en bioingeniería, diseño de proteínas y exploración de candidatos farmacológicos, demostrando que la predicción de propiedades moleculares a partir de datos secuenciales es factible y útil cuando se combina conocimiento biológico, modelos de lenguaje y herramientas modernas de inteligencia artificial.

Agradecimientos

Agradezco profundamente a mi familia por su acompañamiento constante durante este proceso, y especialmente a mi padre, cuya presencia, apoyo incondicional y palabras de aliento fueron fundamentales incluso en los momentos más difíciles de esta tesis. Su fortaleza y confianza en mí fueron una fuente esencial de motivación y perseverancia.

Apéndice A. Descripción de los Modelos de Embeddings Utilizados

¿Qué son los embeddings proteicos? Una explicación sencilla con ejemplo

Los **embeddings proteicos** son representaciones numéricas de secuencias de aminoácidos generadas por modelos de lenguaje como ESM-2 o ProtTrans. Estos modelos han sido entrenados sobre millones de secuencias reales y aprenden a traducir cada proteína en un vector de números (por ejemplo, de tamaño 1280) que contiene información sobre su estructura, función y relaciones evolutivas, sin necesidad de conocer su forma tridimensional ni usar alineamientos múltiples.

Esta idea se inspira en los avances en procesamiento de lenguaje natural (NLP), donde palabras como “rey” o “reina” pueden representarse como vectores en un espacio que refleja relaciones semánticas. De forma análoga, los embeddings proteicos permiten que modelos de machine learning “entiendan” una proteína al convertir su secuencia en una representación matemática comparable entre diferentes proteínas.

Ejemplo conceptual (simplificado a 2 dimensiones):

Imaginemos tres secuencias de proteínas hipotéticas:

- Secuencia A: MKTAY
- Secuencia B: MKDAY
- Secuencia C: PQGLL

Luego de ser procesadas por un modelo como ESM-2, cada secuencia se representa como un punto en el espacio numérico (embedding). En este caso, simplificamos el embedding a solo dos dimensiones para facilitar la visualización:

Secuencia	Embedding (x, y)
A	(1.2, 3.4)
B	(1.1, 3.6)
C	(-2.0, 0.5)

Table 4: Ejemplo de embeddings simplificados en 2D para tres secuencias proteicas




Figure 11: Visualización simplificada de embeddings proteicos en 2 dimensiones. Las secuencias A y B aparecen cercanas debido a su similitud, mientras que la secuencia C está más alejada.

En este espacio vectorial:

- Las secuencias A y B están cercanas porque son similares (solo difieren en una letra).

- La secuencia C está alejada, reflejando que es estructural o funcionalmente distinta.

Aunque los modelos reales generan vectores mucho más largos (por ejemplo, de 1280 dimensiones), esta representación permite que los algoritmos de aprendizaje automático encuentren patrones y hagan predicciones como la temperatura de fusión, a partir únicamente de la secuencia de la proteína.

En resumen, los embeddings actúan como una “traducción matemática” de las proteínas, capturando sus propiedades biológicas de forma compacta y útil para tareas computacionales.

Modelo ESM-2 (Evolutionary Scale Modeling 2)

ESM-2 es una serie de modelos de lenguaje profundo desarrollados por Meta AI, basados en arquitecturas Transformer entrenadas sobre grandes bases de datos de secuencias proteicas. Su objetivo es capturar relaciones evolutivas y estructurales directamente desde la secuencia primaria de aminoácidos, sin necesidad de alineamientos múltiples ni estructuras tridimensionales. El modelo utilizado en este trabajo corresponde a la versión `esm2_t33_650M_UR50D`, compuesto por 33 capas y 650 millones de parámetros, entrenado sobre la base UR50D. Este modelo ha demostrado un desempeño destacado en tareas como la predicción de contactos, anotaciones funcionales y predicción de estructuras secundarias [21].

La arquitectura de ESM-2 se inspira en los avances del modelado del lenguaje natural, y su entrenamiento autosupervisado le permite aprender representaciones latentes que reflejan la evolución y función de las proteínas. Estas representaciones, conocidas como embeddings, pueden ser utilizadas como entrada para tareas de predicción, como en este caso la estimación de la temperatura de fusión.

Modelo ProtTrans

ProtTrans es una colección de modelos de lenguaje profundo diseñados específicamente para secuencias de proteínas, desarrollados por Rostlab y colaboradores. Incluye múltiples arquitecturas preentrenadas como BERT, T5, XLNet y Albert, adaptadas para tareas bioinformáticas. Estos modelos fueron entrenados sobre la base Big Fantastic Database (BFD) y UniRef50, que contienen más de 2.1 mil millones de secuencias únicas, lo que les permite capturar características ricas de estructura, función y evolución proteica [22].

En particular, el modelo ProtBERT —utilizado en esta investigación— se basa en la arquitectura BERT y está optimizado para representar relaciones bidireccionales en la secuencia de aminoácidos. Los embeddings generados por ProtTrans han sido aplicados con éxito en tareas como clasificación funcional, predicción de regiones desordenadas, y evaluación de mutaciones.

Ambos modelos —ESM-2 y ProtTrans— permiten convertir secuencias de proteínas en vectores numéricos de alta dimensionalidad que resumen información relevante sin necesidad de estructuras tridimensionales. Esto los hace especialmente útiles en contextos donde solo se dispone de la secuencia primaria, como en predicciones de propiedades biofísicas o diseño de proteínas.

Apéndice B. Descripción de las Bases de Datos Utilizadas

ProThermDB

ProThermDB es una base de datos curada que recopila información termodinámica sobre la estabilidad de proteínas, incluyendo datos experimentales sobre temperatura de fusión (T_m), energía libre (ΔG), entalpía (ΔH), y condiciones experimentales. Fue diseñada originalmente para estudios de mutagénesis dirigida y contiene una combinación de entradas tipo *wild-type* y mutantes [17].

En este proyecto se utilizó un subconjunto de aproximadamente ****11,000 entradas****, seleccionadas por contener valores completos de temperatura de fusión. Si bien la base original contiene decenas de columnas, las más relevantes consideradas para el modelado fueron:

- **PROTEIN**: Nombre de la proteína.
- **UniProt_ID**: Identificador en UniProt.
- **MUTATION**: Mutación específica reportada (cuando aplica).
- **PDB_wild**: Código PDB asociado a la estructura tipo salvaje (si disponible).
- **Tm (°C)**: Temperatura de fusión medida experimentalmente.

Ejemplo de entrada de ProThermDB:

No.	PROTEIN	UniProt_ID	MUTATION	Tm (°C)
32	Major prion protein	P04156	T183A	44.7
152	Guanylyl cyclase-activating protein 1	P43080	wild-type	49.8
158	Guanylyl cyclase-activating protein 1	P43080	V160G	40.7

Table 5: Ejemplo de entradas en ProThermDB utilizadas en este estudio

Para el modelado, las secuencias completas de las proteínas fueron posteriormente recuperadas usando los identificadores UniProt y herramientas de extracción externas (API UniProt), ya que no estaban incluidas directamente en la base.

Meltome Atlas

Meltome Atlas es una base de datos moderna que contiene perfiles de estabilidad térmica de proteínas tipo *wild-type* recolectados mediante técnicas de proteómica cuantitativa en organismos de distintas especies. Fue generada mediante experimentos de meltome profiling y contiene más de ****25,000 entradas únicas**** [18]. Esta base fue utilizada para entrenar el modelo final de este proyecto por su calidad, diversidad y cobertura taxonómica.

Las columnas relevantes consideradas incluyeron:

- **Protein name / UniProt ID.**
- **T_m (°C):** Temperatura de fusión observada.
- **Organism:** Organismo de origen.
- **Sequence:** Secuencia aminoacídica (recuperada vía UniProt).
- **Replicate / Experimental condition.**

Ejemplo de entrada de Meltome Atlas:

UniProt ID	Organism	T _m (°C)	Sequence (resumen)
P12345	<i>E. coli</i>	63.2	MKE...LTD (284 aa)
P67890	<i>H. sapiens</i>	52.8	MAD...LSK (177 aa)

Table 6: Ejemplo de entradas en Meltome Atlas

Ambas bases fueron preprocesadas para asegurar consistencia, eliminar duplicados y excluir entradas sin datos de T_m o secuencias válidas. El conjunto resultante sirvió como base para generar los embeddings y entrenar los modelos de predicción.

Apéndice C. Extracción de Secuencias desde UniProt

Para obtener las secuencias completas de aminoácidos de cada proteína, se utilizó la API REST de UniProt (<https://rest.uniprot.org/>), empleando como entrada los identificadores contenidos en la tabla `cross-species.csv`. La consulta se realizó en formato batch, recuperando secuencias en formato `fasta` o JSON según disponibilidad.

Ejemplo de URL de consulta:

`https://rest.uniprot.org/uniprotkb/P12345.fasta`

Fragmento de resultado en formato FASTA:

```
>sp|P12345|EXAMPLE_PROT_HUMAN Example protein OS=Homo sapiens
MSEQNNTEMTFQIQRIYTKDISFEAPNAPHVVFQKDWDLAVDAEDGATLEKFD RFKHLK
```

En total, se extrajeron más de 20,000 secuencias. Las secuencias fueron validadas para asegurar su longitud y contenido estándar de 20 aminoácidos canónicos. El proceso de extracción fue automatizado mediante un script en Python utilizando la biblioteca `requests` y control de errores por códigos HTTP.

References

- [1] G. Feller and C. Gerday, "Thermostability and the adaptation of psychrophilic proteins to the cold," *Journal of Biological Chemistry*, vol. 270, no. 16, pp. 9681-9686, 1995.

- [2] M. E. Stroppolo, et al., "Superoxide dismutases: A review...", *Cellular and Molecular Life Sciences*, vol. 58, no. 4, pp. 605-616, 2001.
- [3] S. P. Pack, et al., "Structural and functional stability of hyperthermophilic enzymes," *Bioscience, Biotechnology, and Biochemistry*, 2000.
- [4] J. Jumper, et al., "Highly accurate protein structure prediction with AlphaFold," *Nature*, vol. 596, 2021.
- [5] R. Rao, et al., "Evaluating protein transfer learning with TAPE," *NeurIPS*, vol. 32, 2019.
- [6] J. Meier, et al., "Language models enable zero-shot prediction...", *NeurIPS*, vol. 34, 2021.
- [7] N. Sélem-Mojica, T. Karakulak, A. Anjum, A. Pashkov, R. Pérez-Estrada, K. Enriquez-Guillén, D. DeBlasio, S. Ferreira-Gonzalez, A. Medina-Rivera, D. Rodrigo-Torres, A. M. Kilpatrick, L. R. Welch, and F. Rahman, "Closing the computational biology 'knowledge gap': Spanish Wikipedia as a case study," *Bioinformatics*, vol. 40, no. Supplement_1, pp. i11–i19, Jun. 2024. Available: <https://doi.org/10.1093/bioinformatics/btae247>
- [8] S. Yeni, N. Grgurina, F. F. J. Hermans, J. L. J. Tolboom, and E. Barendsen, "Exploring Teachers' PCK for Computational Thinking in Context," in *Proceedings of the 16th Workshop in Primary and Secondary Computing Education (WiPSCE)*, 2021. DOI: 10.1145/3481312.3481320
- [9] N. Phaphoom, X. Wang, S. Samuel, S. Helmer, and P. Abrahamsson, "A survey study on major technical barriers affecting the decision to adopt cloud services," *Journal of Systems and Software*, vol. 103, pp. 167–181, 2015. DOI: 10.1016/j.jss.2014.12.027
- [10] Q. Kuang, Y. Zhao, J. Wang, L. Cheng, and Z. Zhang, "PON-Tm: A Sequence-Based Method for Prediction of Missense Mutations on Protein Thermal Stability," *Bioinformatics Advances*, vol. 4, no. 1, Mar. 2024. doi: 10.1093/bioadv/vbad170
- [11] M. Hecht, U. Sturtevant, and P. Matthews, "The effect of single amino acid replacements on the thermal stability of a protein," *Protein Science*, vol. 8, no. 1, pp. 153–163, 1999. Available: <https://doi.org/10.1002/pro.5560080117>
- [12] F. Pucci, R. Bourgeas, and M. Rooman, "Predicting protein thermal stability changes upon point mutations using statistical potentials: Introducing HoTMuSiC," *Scientific Reports*, vol. 6, 2016. Available: <https://doi.org/10.1101/038554>
- [13] R. Farhoodi, M. Shelbourne, R. Hsieh, N. Haspel, B. Hutchinson, and F. Jagodzinski, "Predicting the effect of point mutations on protein structural stability," in *Proc. of the 8th ACM Int. Conf. on Bioinformatics, Computational Biology, and Health Informatics*, 2017. Available: <https://doi.org/10.1145/3107411.3107492>
- [14] G. Feller and C. Gerday, "Thermostability and the adaptation of psychrophilic proteins to the cold," *Journal of Biological Chemistry*, vol. 270, no. 16, pp. 9681–9686, 1995.

- [15] F. Pucci, R. Bourgeas, and M. Rooman, "Predicting protein thermal stability changes upon point mutations using statistical potentials: Introducing HoTMuSiC," *Scientific Reports*, vol. 6, 2016. Available: <https://doi.org/10.1101/038554>
- [16] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.
- [17] M. D. Kumar, K. Bava, M. Gromiha, S. Prabakaran, A. Kitajima, H. Uedaira, and A. Sarai, "ProTherm and ProNIT: thermodynamic databases for proteins and protein–nucleic acid interactions," *Nucleic Acids Research*, vol. 34, no. Suppl_1, pp. D204–D206, Jan. 2006. DOI: 10.1093/nar/gkj103
- [18] A. Jarzab, N. Kurzawa, T. A. Hopf, M. Moerch, J. Zecha, N. Leijten, Y. Bian, E. Musiol, M. Maschberger, G. Stoehr, *et al.*, "Meltome atlas—thermal proteome stability across the tree of life," *Nature Methods*, vol. 17, pp. 495–503, 2020. doi: [10.1038/s41592-020-0801-4](<https://doi.org/10.1038/s41592-020-0801-4>).
- [19] M. S. Klausen, M. C. Jespersen, H. Nielsen, K. K. Jensen, M. Nielsen, B. Petersen, and P. Marcatili, "NetSurfP-2.0: Improved prediction of protein structural features by integrated deep learning," *Proteins: Structure, Function, and Bioinformatics*, vol. 87, no. 6, pp. 520–527, Jun. 2019. doi: 10.1002/prot.25674
- [20] A. Elnaggar, M. Heinzinger, C. Dallago, G. Rehawi, Y. Wang, L. Jones, T. Gibbs, T. Feher, T. Angerer, M. Steinegger, D. Bhowmik, and B. Rost, "ProtTrans: Towards Cracking the Language of Life's Code Through Self-Supervised Deep Learning and High Performance Computing," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021. arXiv preprint: arXiv:2007.06225
- [21] J. Meier, M. Rao, A. Verkuil, J. Liu, C. Sercu, and A. Rives, "Language models enable zero-shot prediction of the effects of mutations on protein function," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, pp. 29287–29303, 2021. Available: https://proceedings.neurips.cc/paper_files/paper/2021/hash/e6385c32cdd3efebbaldfc213f2bca86-Abstract.html
- [22] A. Elnaggar, M. Heinzinger, C. Dallago, G. Rehawi, Y. Wang, L. Jones, T. Gibbs, T. Feher, T. Angerer, M. Steinegger, D. Bhowmik, and B. Rost, "ProtTrans: Towards Cracking the Language of Life's Code Through Self-Supervised Deep Learning and High Performance Computing," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021. arXiv preprint: <https://arxiv.org/abs/2007.06225>
- [23] Liao, W., Rubinsteyn, A., and Whalley, I. (2013). *Learning random forests on the GPU*. arXiv preprint arXiv:1311.2022. doi: 10.48550/arXiv.1311.2022
- [24] Hernández-Fabelo, Y., Almeida-Cruz, Y., and García-Peñalvo, F. J. (2017). *Random Forest training stage acceleration using Graphics Processing Units*. In Proceedings of the International Conference on Computer Supported Education. doi: 10.5220/0006328803810388

- [25] Essen, B., Macaraeg, C., and Keutzer, K. (2012). *Accelerating a Random Forest classifier: Multicore, GPGPU, or both?* In 2012 IEEE International Conference on Computer Vision Workshops. doi: 10.1109/IC-CVW.2011.6130325